

# Sprawozdanie z przedmiotu Modelowanie systemów dynamicznych.

Temat laboratoriów: Identyfikacja obiektu regulacji

Filip Pasternak, Grupa lab. 7, środa godz 13:45.

## Identyfikacja modelu A metodą wyznaczania parametrów na podstawie odpowiedzi skokowej.

$$G(s) = \frac{ke^{-s\theta}}{Ts+1} \quad \left| \begin{array}{l} \text{obiekt inercyjny I rzędu z opóźnieniem} \\ \text{Transmitancja modelu A} \end{array} \right.$$

Metoda ta polega na manualnym dobraniu parametrów obiektu tak, aby błąd wynikający z porównania tych dwóch wykresów był jak najmniejszy.

```
t = 1:1:60;

% A
% 2.1
k = 2.145;
T = 15.7;
theta = 7.7;


obiektA = tf([0 k], [T 1])
set(obiektA, 'outputDelay', theta)

figure
hold on
step(obiektA)
plot(t, y)
xlim([0 60])

% bład aproksymacji:
e = y - step(obiektA, t);
RMS = sum(e.^2)/length(e)
```

RMS = 0.0016

Najmniejszy błąd jaki udało mi się osiągnąć wynosił 0.0016, co jest nie najgorszym wynikiem, zwłaszcza widząc jak oba wykresy na siebie się nakładają.



## Identyfikacja modelu A metodą optymalizacji numerycznej.

Jest to metoda która jest swoim działaniem bardzo zbliżona do metody użytej poprzednio, jednak w tym przypadku parametry są dobrane automatycznie przy użyciu wbudowanej w środowisko Matlab funkcji *fminsearch()*. Funkcja ta zwraca parametry obiektu dla których błąd jest najmniejszy.

Do wykonania tego typu identyfikacji została zdefiniowana nowa funkcja obliczająca błąd dla modelu A. Została ona opisana w oddzielnym skrypcie *ident*.

```
function blad = ident(X0)
load obiekt.mat
k = X0(1);
T = X0(2);
theta = X0(3);

t = 1:1:60;

obiektA = tf([0 k], [T 1]);
set(obiektA, 'outputDelay', theta);
y_sym = step(obiektA, t);

e = y - y_sym;
blad = sum(e.^2) / length(e);
```

% 2.4


```
[parameter, blad] = fminsearch('ident',[1,1,1])
```

```
parameter = 1×3  
    2.1422    15.4254    8.0971  
blad = 0.0015
```

```
obiektA = tf([0 parameter(1)], [parameter(2) 1])  
set(obiektA, 'outputDelay', parameter(3))
```

```
figure  
hold on  
step(obiektA)  
plot(t, y)  
xlim([0 60])
```

Błąd tym razem wyniósł 0.0015, co jest lepszym wynikiem w porównaniu z manualnym dobieraniem parametrów.



## Identyfikacja modelu B za pomocą metody optymalizacji numerycznej.

Metoda jest ta sama co w poprzednim przykładzie, jednak kod wymagał lekkich modyfikacji ze względu na pracę z obiektem innego typu:

$$G(s) = \frac{ke^{-s\theta}}{(T_1s+1)(T_2s+1)} \quad \left| \begin{array}{l} \text{obiekt inercyjny II rzędu z opóźnieniem} \\ \text{(aproxymacja Kupfmuellera)} \end{array} \right. \quad \text{Transmitancja modelu B}$$

Podobnie jak poprzednio, do użycia funkcji *fminsearch()* został wykorzystany oddzielny skrypt obliczający błąd dla modelu II rzędu *ident2*

```
function blad = ident2(X0)
load obiekt.mat
k = X0(1);
T1 = X0(2);
T2 = X0(3);
theta = X0(4);

t = 1:1:60;

obiektB = tf([0 0 k], conv([T1 1], [T2 1]));
set(obiektB, 'outputDelay', theta);

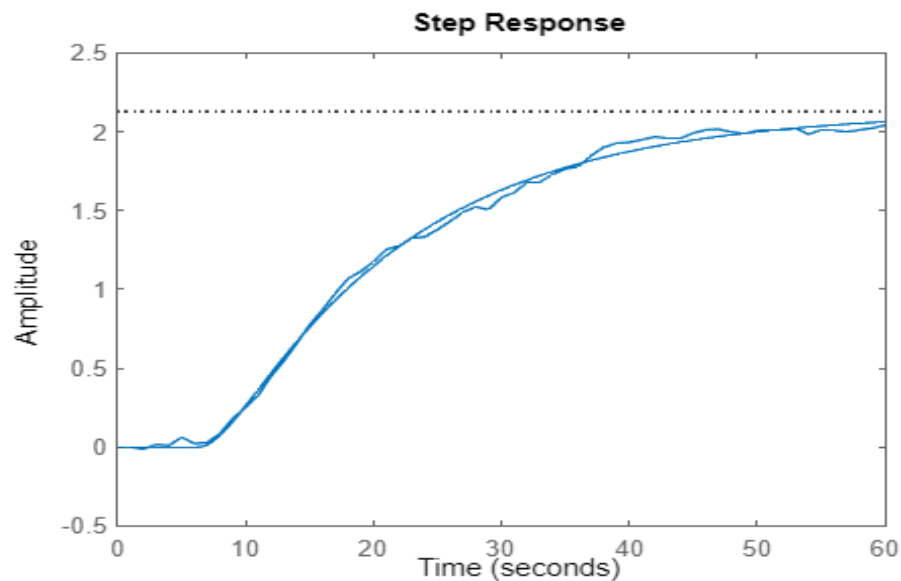
y_sym = step(obiektB, t);
e = y - y_sym;
blad = sum(e.^2) / length(e);
```

```
% B
% 2.4
[parametry_b, blad_b] = fminsearch('ident2',[1,1,1,1])
```

```
parametry_b = 1x4
    2.1292    2.0541   14.8405    6.2836
blad_b = 0.0013
```

```
obiektB = tf([0 0 parametry_b(1)], conv([parametry_b(2) 1], [parametry_b(3)
1]));
set(obiektB, 'outputDelay', parametry_b(4))

figure
hold on
step(obiektB)
plot(t, y)
xlim([0 60])
```



## Identyfikacja modelu C za pomocą metody optymalizacji numerycznej.

Tak samo jak w poprzednim przykładzie kod wymagał pewnych (w tym przypadku znaczniejszych) modyfikacji, ponieważ pracujemy w tym przypadku z obiektem o nieokreślonym rzędzie.

Zamiast jednego dodatkowego skryptu napisałem ich 4 dla każdego badanego rzędu: *ident3a*, *ident3b*, *ident3c* oraz *ident4d*.

```
function blad = ident3a(X0)
load obiekt.mat
k = X0(1);
T = X0(2);

global n;

t = 1:1:60;

obiektC = zpke([], [-T, -T], k);
y_sym = step(obiektC, t);

e = y - y_sym;
blad = sum(e.^2) / length(e);
```

Dla kolejnych rzędów jedyną zmianą jest zwiększenie ilości biegunów -T.

```
% C
[parametry_c_rzad2, blad_c_rzad2] = fminsearch('ident3a', [1 1])
[parametry_c_rzad3, blad_c_rzad3] = fminsearch('ident3b', [1 1])

parametry_c_rzad3 = 1x2
    0.0058    0.1411
blad_c_rzad3 = 0.0027
```


```
[parametry_c_rzad4, blad_c_rzad4] = fminsearch('ident3c', [1 1])
```

```
parametry_c_rzad4 = 1×2  
    0.0030    0.1967  
blad_c_rzad4 = 0.0032
```


```
[parametry_c_rzad5, blad_c_rzad5] = fminsearch('ident3d', [1 1])
```

```
parametry_c_rzad5 = 1×2  
    0.0020    0.2522  
blad_c_rzad5 = 0.0055
```


```
obiektC_rzad2 = zpk([], [-parametry_c_rzad2(2), -  
parametry_c_rzad2(2)],parametry_c_rzad2(1));  
obiektC_rzad3 = zpk([], [-parametry_c_rzad3(2), -parametry_c_rzad3(2), -  
parametry_c_rzad3(2)],parametry_c_rzad3(1));  
obiektC_rzad4 = zpk([], [-parametry_c_rzad4(2), -parametry_c_rzad4(2), -  
parametry_c_rzad4(2), -parametry_c_rzad4(2)],parametry_c_rzad4(1));  
obiektC_rzad5 = zpk([], [-parametry_c_rzad5(2), -parametry_c_rzad5(2), -  
parametry_c_rzad5(2), -parametry_c_rzad5(2), -  
parametry_c_rzad5(2)],parametry_c_rzad5(1));  
% obiekt rzadu 2  
figure  
hold on  
step(obiektC_rzad2)  
plot(t, y)  
xlim([0 60])
```



```
% obiekt rzędu 3  
figure  
hold on  
step(obiektC_rzad3)  
plot(t, y)  
xlim([0 60])
```




```
% obiekt rzędu 4  
figure  
hold on  
step(obiektC_rzad4)  
plot(t, y)  
xlim([0 60])
```



```

% obiekt rzędu 5
figure
hold on
step(obiektC_rzad5)
plot(t, y)
xlim([0 60])

```



Rząd	K	T	Błąd
2	0.0156	0.0844	0.0073
3	0.0058	0.1411	0.0027
4	0.0030	0.1967	0.0032
5	0.0020	0.2522	0.0055

Można wyciągnąć prosty wniosek, że dla obiektu inercyjnego rzędu III bez opóźnienia metoda optymalizacji numerycznej zwraca najdokładniejszy wynik. Wraz z dalszym wzrostem rzędów, zwiększa się także błąd jednocześnie pogarszając jakość naszej aproksymacji.